

Amazon 商业化数据分析最终报告

一、分析过程

第一阶段：数据工程与业务理解

1. 数据获取与初步探索

项目首先从 Amazon 电商数据的获取与初步探索开始。我使用 Pandas 导入商品数据集，并查看数据规模、字段名称、数据类型、缺失值和重复值情况，以了解数据的整体结构。原始商品数据共包含 1,465 条记录和 16 个字段，主要涵盖商品 ID、商品名称、类别、原价、折后价、折扣率、评分、评分人数、商品描述以及用户评论等信息。通过初步探索，我明确了各字段的业务含义，并确定后续分析将主要围绕商品价格、折扣、评分、用户行为和评论文本展开。

原始数据结构表：

数据集	记录数	字段数	主要内容
Amazon 商品数据	1,465	16	商品、价格、评分、评论
Electronics 评分数据	7,824,482	4	用户、商品、评分、时间

2. 数据清洗

在了解原始数据结构后，我对商品数据进行了进一步清洗。首先对价格、折扣率和评分等字段中的货币符号、百分号等字符进行处理，并将相关字段转换为可计算的数值类型；随后检查缺失值、重复记录和异常值。对于商品价格，我使用四分位距（IQR）方法识别异常数据，并对数据进行筛选整理。经过清洗后，最终得到 1,247 条可用于后续分析的商品记录，其中包含 1,136 个不同的商品 ID，为后续商品、价格和评论分析建立了较稳定的数据基础。

项目	清洗前	清洗后
数据记录数	1,465	1,247
唯一商品数	—	1,136
价格字段	文本格式	数值格式
异常/缺失数据	存在	已处理

3. 数据整合与宽表构建

完成数据清洗后，我进一步对不同数据源进行整合。商品数据中包含商品名称、类别、价格、折扣、评分和评论等信息，而大规模评分数据主要包含用户 ID、商品 ID、评分和时间戳。由于两个数据集都包含 product_id 字段，因此我尝试以 product_id 作为关联键，将商品信息与用户评分数据进行匹配，并生成用于后续分析的数据宽表。通过这一过程，可以在同一数据结构中同时保留商品属性和用户评分行为，为后续用户分析和推荐模型提供数据基础。第一阶段任务本身也要求通过关键字段整合多个数据集，并构建可用于分析的数据宽表。

不过在后续分析中，我发现两个数据集的商品覆盖范围并不完全一致，因此能够成功匹配的商品较少。基于这一限制，后续商品价格、类别和评论分析主要使用清洗后的商品数据，而推荐系统和用户行为分析主要使用规模更大的评分数据，避免因强行合并造成大量数据损失。

数据源	主要字段	主要用途
amazon_cleaned.csv	product_id、category、price、rating、review	商品、价格、评论分析
ratings_Electronics.csv	user_id、product_id、rating、timestamp	用户分析、推荐模型
amazon_wideTable.csv	两个数据源匹配后的字段	数据关联与整合验证

4. 数据字典与业务指标定义

完成数据清洗和整合后，我对清洗后的数据字段进行了统一整理，并建立数据字典，对各字段的数据类型、业务含义和示例值进行说明。数据字典共覆盖商品 ID、商品名称、商品类别、原价、折后价、折扣率、商品评分、评价人数、评论内容等 16 个字段，使后续分析过程中能够保持字段含义和使用方式的一致。

同时，我根据第一阶段任务要求对 GMV、转化率、复购率和平均评分等业务指标进行了梳理。在实际检查数据后，我发现当前数据集并不包含真实订单数量、曝光量和点击量，因此无法严格计算真实 GMV 和转化率，复购行为也缺少完整订单依据。因此，后续分析主要使用数据能够可靠支持的指标，例如商品评分、评价数量、价格、折扣率以及用户评分行为，并将数据缺失造成的指标限制保留在最终报告中说明。

数据字典示例：

字段名	数据类型	业务含义	示例数据
product_id	str	商品的唯一识别码	B07JW9H4J1
product_name	str	商品名称	Wayona Nylon Brai
category	str	商品所属分类	Computers&Accesso
discounted_price	float64	商品促销后的折扣价	399
actual_price	float64	商品原价	1099
discount_percentag	str	折扣百分比	64%
rating	float64	商品综合评分	4.2
rating_count	float64	累计评价人数	0
about_product	str	商品详情描述	High Compatibilit
user_id	str	发表评论的用户ID	AG3D604STAQKAY2UV
user_name	str	发表评论的用户名	Manav, Adarsh gupt
review_id	str	单条评论的ID	R3HXWT0LRPONMF, R2
review_title	str	评论的标题	Satisfied, Chargin
review_content	str	评论的具体内容	Looks durable Cha
img_link	str	商品的图片链接	https://m.media-a
product_link	str	商品详情页的链接	https://www.amazo

业务指标可用性说明：

指标	当前数据可用性
平均评分	可计算
GMV	缺少真实销量，无法严格计算
转化率	缺少曝光/点击/订单数据
复购率	缺少完整购买订单记录

第二阶段：探索性分析与可视化


1. 不同商品类目的价格分布分析

进入探索性分析阶段后，我首先对不同商品类目的价格水平进行比较。分析时先按照 `product_id` 对商品进行去重，并从完整分类字段中提取一级商品类目。由于部分类目仅包含 1-2 个商品，样本量过小，因此正式分析仅保留商品数量不少于 10 的类目，最终包括 `Home&Kitchen`、`Electronics`、`Computers&Accessories` 和 `OfficeProducts` 四个主要类目。随后分别计算各类目的平均折后价、中位折后价以及价格分布情况，并使用柱状图和箱线图进行比较。


分析结果显示，`Home&Kitchen` 的整体价格水平最高，其次为 `Electronics`、`Computers&Accessories` 和 `OfficeProducts`。四个主要类目的平均价格均高于中位价格，说明少数高价商品对平均值产生了明显影响；从箱线图来看，

Electronics 和 Computers&Accessories 还存在较多高价离群商品，而 OfficeProducts 的整体价格水平最低。

不同商品类目的平均折后价与中位折后价横向柱状图



不同商品类目的折后价分布箱线图



2. 多维度对比实验

在完成不同商品类目的价格分布分析后，我进一步加入折扣率、商品评分和评价数量进行多维度比较。为保证不同类目之间具有基本可比性，分析仍只保留商品数量不少于 10 的 Home&Kitchen、Computers&Accessories、Electronics 和 OfficeProducts 四个主要类目。随后分别进行“商品类目 × 价格 × 折扣”和“商品类目 × 评分 × 评价热度”两组对比实验。

类目	平均折后价	平均折扣率	平均评分	评分人数中位数
Home&Kitchen	₹1,321.49	40.19%	4.01	2,127
Computers&Accessories	₹639.26	53.77%	4.15	7,318
Electronics	₹993.89	57.34%	4.05	9,090
OfficeProducts	₹301.58	12.35%	4.31	4,426

(1) 商品类目 × 价格 × 折扣

第一组实验比较不同商品类目的价格水平和促销力度。结果显示，Electronics 的平均折扣率最高，为 57.34%，Computers&Accessories 次之，为 53.77%；Home&Kitchen 为 40.19%，而 OfficeProducts 仅为 12.35%。结合价格水平来看，不同商品类目呈现出明显不同的定价与折扣策略。

(2) 商品类目 × 评分 × 评价热度

第二组实验进一步比较商品评分和评价热度。OfficeProducts 的平均评分最高，为 4.31；Electronics 的评分人数中位数最高，达到 9,090，说明其评价热度最高；Computers&Accessories 的平均评分为 4.15，评分人数中位数为 7,318，整体表现较为均衡；Home&Kitchen 虽然商品数量最多，但评分人数中位数仅为 2,127，评价热度相对较低。


3. 高活跃用户分析

由于原始数据缺少用户真实订单金额、购买数量等信息，因此无法按照消费金额定义传统意义上的“高价值用户”。我改用用户评分行为构建高活跃用户画像，根据用户评价商品数量和活跃时间对用户进行排序，并将排名前 10% 的用户定义为高活跃用户，其余用户定义为普通用户。随后比较两类用户的平均评价商品数、平均评分、好评率、差评率以及活跃时间等指标。


分析结果显示，高活跃用户平均评价商品数量为 6.93 件，明显高于普通用户的 1.30 件；平均评分分别为 4.13 和 3.89。高活跃用户的平均好评率为 77.51%，高于普通用户的 71.24%，而平均差评率为 14.02%，低于普通用户的 21.07%。此外，高活跃用户平均活跃时间达到 1,041 天，而普通用户仅为 81.5

天。整体来看，高活跃用户不仅参与评价的频率更高，而且持续活跃时间更长，评价倾向也更加正面。

高活跃用户与普通用户的平均评分柱状图



高活跃用户与普通用户的好评率和差评率对比柱状图




4. 总体评分分布分析

为了了解用户对商品的整体评价倾向，我对大规模 Electronics 评分数据中的 1-5 星评分进行了统计，并分别计算各星级评分的数量和占比。该数据集共包含 7,824,482 条评分记录，其中 5 星评分数量最多，为 4,347,541 条，占 55.56%；4 星评分为 1,485,781 条，占 18.99%。4 星和 5 星评分合计约占 74.55%，说明整体评分明显集中在较高评分区间。

相比之下，1 星评分占 11.52%，2 星评分占 5.83%，3 星评分占 8.09%。总体平均评分约为 4.01 分，中位数和众数均为 5 分，进一步说明该评分数据整体呈现较明显的正向评价倾向。

总体评分分布图




5. 评论文本长度与商品评分关系分析


为了进一步分析评论内容与商品评分之间的关系，我按照 `product_id` 对商品进行去重，并对 `review_content` 计算字符数和英文单词数。随后将商品综合评分划分为不同区间，比较各评分组的评论文本长度，并计算评分与评论长度之间的相关系数。

结果显示，4-5 分商品的平均评论文本长度高于部分低评分组，但从整体相关性来看，商品评分与评论文本长度之间的线性关系非常弱。评分与评论字符数的相关系数约为 0.049，评分与评论单词数的相关系数同样约为 0.050。因此，不能简单认为评论越长，商品评分就越高；不同评分组之间虽然存在平均长度差异，但评论长度本身并不是评分高低的重要解释因素。

不同评分组的评论文本长度分布箱线图



评分组与评论文本长度关系散点图



6. 评论高频词与词云分析

为了进一步了解用户在商品评论中经常关注的内容，我对 `review_content` 进行文本清洗，包括统一小写、去除停用词和低分析价值词汇，并使用 `Counter` 统计词频。随后根据真实词频生成词云，从整体上观察评论中高频出现的产品属性和使用体验。

分析结果显示, good 是出现频率最高的词, 共出现 4,507 次; 此外, quality、cable、price 分别出现 1,642 次、984 次和 935 次。除了一些较为泛化的正面词汇外, 用户还频繁讨论质量、价格、充电、电池、线缆和声音等具体产品属性, 说明这些内容是用户评价商品体验时较常涉及的关注点。

Amazon 商品评论词云图




7. Tableau 交互式仪表盘

为了将前面的探索性分析结果集中展示，我使用 Tableau 构建了交互式数据仪表盘。首先将 category_price_summary.csv、user_group_comparison.csv、rating_distribution.csv、review_length_rating_summary.csv 和 top_20_review_words.csv 五个分析结果文件整合为统一的数据源，并分别建立 Category Price、User Comparison、Rating Distribution、Review Length 和 Top Words 五个工作表。

在仪表盘中，我集中展示了不同商品类目的平均价与中位价、总体评分分布、高活跃用户与普通用户的行为差异、评分与评论文本长度关系以及评论高频词 Top 20 等结果。通过将多个分析结果放在同一仪表盘中，可以更直观地比较商品、用户和评论三个维度的信息，并提高后续结果展示和商业分析的效率。

Tableau 综合数据仪表盘图




第三阶段：建模与深度洞察

1. 评论情感分析


本阶段首先对 Amazon 商品评论进行更深入的情感分析。由于原始数据中的 `review_content` 并不是“一行一条评论”，而是以商品为单位汇总了多条评论文本，且不同评论之间缺少可靠统一的分隔符，因此我没有强制拆分评论，而是将每个商品对应的评论文本集合作为一个分析单位。随后使用 NLTK 中的 VADER 模型，对每组评论计算 `compound score`，并按照 `compound ≥ 0.05` 为 Positive、`compound ≤ -0.05` 为 Negative，其余为 Neutral 的规则进行情感分类（Hutto & Gilbert, 2014）。

本次共分析 1,247 个商品评论文本单元，其中 1,177 个呈正向情感，占 94.39%；59 个呈负向情感，占 4.73%；11 个呈中性情感，占 0.88%，说明整体评论情绪明显偏正面。进一步将商品评分与 VADER 情感得分进行比较后发现，大多数高分商品的文本情感也为正，但仍存在部分“高分但负面评论”的异常情况，例如 Dell MS116 Mouse 的评分为 4.5，但情感得分为 -0.8380；Fire-Boltt Ninja Calling 的评分为 4.2，但情感得分为 -0.9273。这说明文本情感分析能够补充单纯星级评分无法完全反映的用户体验信息。

评论情感分布柱状图



商品评分与评论情感得分关系散点图




2. LDA 主题建模

在完成情感分析后，我进一步使用 LDA 主题模型对评论文本进行主题提取，以识别用户讨论较多的核心内容。首先从 `amazon_cleaned.csv` 中提取评论文本，并使用 `CountVectorizer` 将非结构化文本转换为词频矩阵；随后建立 LDA 模型，将评论文本划分为 5 个潜在主题，并根据每个主题中权重最高的关键词对主题含义进行解释 (Blei et al., 2003)。同时统计每个主题对应的文本数量和占比，用于比较不同主题在评论中的分布情况。

最终识别出的五类主题分别为 Audio & Earphones、Smartwatch Features、Home Appliance Usage、General Product Experience 和 Charging & Cables。其中，General Product Experience 占比最高，为 **54.53%**，主要涉及产品质量、价格和整体使用体验；Charging & Cables 占 **24.38%**，是第二大主题；Audio & Earphones 和 Smartwatch Features 分别占 **10.83%** 和 **8.50%**，Home Appliance Usage 占比最低，为 **1.76%**。结果说明，用户评论除了讨论特定产品功能外，大量内容仍集中在质量、价格和整体使用体验等较普遍的问题上。

LDA 主题分布柱状图



3. 推荐系统构建与评估

(1) 目标与数据准备

在完成评论情感分析和主题建模后，我进一步利用大规模用户评分数据构建商品推荐系统。模型目标是根据用户过去对商品的评分行为，识别具有相似评分模式的商品，并据此为用户生成 Top-N 商品推荐，模拟电商平台中的“相似商品推荐”或个性化推荐功能。原始 Electronics 评分数据包含 7,824,482 条评分记录、4,201,696 名用户和 476,002 个商品，但用户与商品之间的交互非

常稀疏。统计发现，大量用户只对少量商品进行过评分，因此如果直接建立 User-Item Matrix，会产生大量空值，不利于协同过滤模型计算。为提高评分矩阵中有效交互信息的比例，我首先对低活跃用户和低频商品进行筛选，再使用筛选后的数据构建推荐模型。

(2) 评分数据筛选阈值对比实验

在初步构建评分矩阵后，我发现矩阵稀疏度达到 99.6826%，商品之间能够利用的共同评分信息较少，初始测试中最高商品相似度仅约为 0.1370。为了在保留足够数据规模的同时降低矩阵稀疏程度，我进一步对用户最低评分次数和商品最低被评分次数设置不同阈值，并重点比较各组合下保留的评分记录数和矩阵密度，再结合最终保留的用户数和商品数选择合适的筛选标准。

数	用户最低评分次	商品最低被评分次	评分记录数	矩阵密度
	数	数		
5		50	298,596	0.3174%
5		60	183,575	0.5552%
5		70	69,116	1.4448%
6		50	65,911	1.3484%
5		80	0	—

实验结果表明，提高筛选阈值能够增加矩阵密度，但同时会快速减少可用评分数据。当商品最低被评分次数从 50 提高到 70 时，评分记录由 298,596 条下降至 69,116 条；继续提高至 80 后，迭代筛选无法保留有效数据。因此，综合考虑数据规模与矩阵密度，我最终选择“用户至少评分 5 次、商品至少被评分 60 次”作为筛选标准。该条件下最终保留 183,575 条评分记录、24,751 名用户和 1,336 个商品，矩阵密度为 0.5552%。

(3) Item-Based Collaborative Filtering 模型构建

在确定数据筛选标准后，我使用筛选后的 183,575 条评分记录构建 Product-User Matrix，其中包含 1,336 个商品和 24,751 名用户。矩阵中的每个元素表示某位用户对某个商品的评分，未发生评分交互的位置为空。随后，我使用 Cosine Similarity 计算商品之间的相似度，通过比较不同商品在用户评分行为上的相似模式，识别具有较高关联度的商品。

在此基础上，我构建了 Item-Based Collaborative Filtering 推荐逻辑 (Sarwar et al., 2001)。当用户曾经对某些商品给出较高评分时，模型会寻找与这些商品评分模式相似的其他商品，并根据相似度和用户历史评分计算推荐得分，最终生成 Top-N 推荐列表。这样可以在不依赖商品文

本属性的情况下，仅根据用户历史评分行为实现个性化推荐。以评分数量较多的商品 **B007WTAJTO** 为示例，模型筛选出的部分相似商品如下

相似商品推荐示例表

推荐商品 ID	相似度	共同评分用户数
B00AAIPT76	0.1443	87
B00DR0PDNE	0.1001	155
B002RCLYXG	0.0918	47
B005FYNSPK	0.0897	108
B004G6002M	0.0891	93

(4) 推荐模型评估

为了检验 Item-Based Collaborative Filtering 模型是否能够推荐用户实际感兴趣的商品，我采用 Leave-One-Out 方法构建训练集和测试集。对于每位用户，优先从其评分不低于 4 分的商品中随机抽取 1 个作为测试商品，其余评分记录作为训练数据；对于没有 4 分及以上评分的用户，则随机保留 1 个商品作为测试数据。随后仅使用训练集重新构建商品相似度模型，避免测试信息泄漏到模型训练过程中。

正式评估时，仅将测试评分不低于 4 分的记录视为用户感兴趣的商
品，共有 **24,691 名用户**参与最终评估。模型为每名用户生成 Top 10
推荐结果，并判断被隐藏的测试商品是否出现在推荐列表中。最终共有
2,993 名用户成功命中，得到 **Hit Rate@10 = 12.12%、Precision@10 = 1.21%、Recall@10 = 12.12%**。结果说明模型已经具备一定的推荐能力，但由于评分矩阵仍具有较高稀疏度，可用于计算商品相似性的共同评分信息有限，因此推荐效果仍有进一步提升空间。

Item-Based CF 模型评估结果表

评估指标	结果
训练集评分数	158,824
测试集评分数	24,751
有效评估用户数	24,691
Top 10 命中用户数	2,993
Hit Rate@10	12.12%
Precision@10	1.21%
Recall@10	12.12%

(5) 四种推荐模型横向对比实验


在完成 Item-Based Collaborative Filtering 模型后，我进一步进行横向对比实验，以判断当前数据条件下不同推荐方法的表现。实验选取 **Popularity-Based Recommendation**、**User-Based Collaborative Filtering**、**Item-Based Collaborative Filtering** 和 **Truncated SVD** 四种模型。其中，Popularity-Based 作为非个性化基线模型，User-Based CF 和 Item-Based CF 分别利用用户相似性和商品相似性进行推荐，Truncated SVD 则通过矩阵降维提取潜在评分特征。

为了保证实验结果具有可比性，四种模型均使用相同的训练集、测试集和 Top-10 推荐设置，并统一采用 Hit Rate@10、Precision@10 和 Recall@10 作为评价指标。实验结果如下：

推荐模型	Top 10 命中数	Hit Rate@10	Precision@10	Recall@10
Popularity-Based	1,469	5.95%	0.59%	5.95%
User-Based CF	1,926	7.80%	0.78%	7.80%
Item-Based CF	2,993	12.12%	1.21%	12.12%
Truncated SVD	1,846	7.48%	0.75%	7.48%

对比结果显示，Popularity-Based 的 Hit Rate@10 为 5.95%，说明仅根据商品整体热度进行推荐的效果相对有限。User-Based CF 和 Truncated SVD 分别达到 7.80% 和 7.48%，均优于基线模型。Item-Based CF 在本次实验中表现最佳，Hit Rate@10 达到 12.12%，Precision@10 为 1.21%，Recall@10 为 12.12%。这说明在当前评分数据和实验设置下，基于商品之间评分行为相似性的推荐方式更适合该数据集。

四种推荐模型评估指标对比柱状图



二、 关键业务问题

1. 不同商品类目的价格、折扣和用户关注度有何差异？

类目	商品数	平均折后价	平均折扣率	平均评分	评分人数中位数
Home&Kitchen	386	₹1,321.49	40.19%	4.01	2,127
Computers&Accessories	365	₹639.26	53.77%	4.15	7,318
Electronics	347	₹993.89	57.34%	4.05	9,090
OfficeProducts	31	₹301.58	12.35%	4.31	4,426


从主要商品类目的价格、折扣和用户关注度来看，不同类目表现存在明显差异。Electronics 的平均折扣率最高，为 57.34%，同时评分人数中位数也最高，为 9,090，说明该类目具有较高的用户关注度；Computers&Accessories 在价格、评分和评价热度之间表现较为均衡；Home&Kitchen 商品数量最多、平均价格最高，但评分人数中位数相对较低；OfficeProducts 虽然商品数量较少，但平均评分最高，为 4.31，且平均折扣率仅为 12.35%。

基于以上结果，Electronics 可作为重点营销类目，但应注意控制过度折扣；Home&Kitchen 应重点排查高价格、低关注度商品的定价和展示策略；

Computers&Accessories 可维持稳定投入，并尝试组合销售；OfficeProducts 更适合通过增加曝光和交叉销售提升价值，而不是单纯增加折扣。

2. 高活跃用户与普通用户有什么差异，应该如何针对高活跃用户运营？

指标	高活跃用户	普通用户
用户数量	420,170	3,781,526
平均评分商品数	6.93	1.30
平均评分	4.13	3.89
平均好评率	77.51%	71.24%
平均差评率	14.02%	21.07%
平均活跃天数	1,041	81.5





用户行为分析显示，高活跃用户与普通用户之间存在明显差异。高活跃用户平均评价商品数量为 6.93 件，明显高于普通用户的 1.30 件；其平均评分为 4.13，好评率达到 77.51%，而普通用户分别为 3.89 和 71.24%。此外，高活跃用户平均活跃时间达到 1,041 天，而普通用户仅为 81.5 天，说明高活跃用户具有更持续的互动行为，并且整体

评价倾向更加积极。

基于以上结果，可以针对高活跃用户建立重点用户运营策略，例如提供个性化商品推荐、邀请其参与新品体验和评价活动，并通过会员权益或定向优惠增强持续互动。对于普通用户，则可以通过推荐系统和评价激励提高其参与频率，逐步促进其向高活跃用户转化。

3. 用户评论最关注哪些产品属性和使用体验，这些关注点如何用于营销和产品改进？




高频词包括 quality、price、charging、battery、sound、value 等。

LDA 又识别出了 Audio & Earphones、Smartwatch Features、Home Appliance Usage、General Product Experience、Charging & Cables 五类主题。其中 General Product Experience 占 54.53%，Charging & Cables 占 24.38%。其中 good、product 等词虽然出现频率较高，但商业区分度较低，因此重点关注更具有产品属性含义的词汇。

从评论内容来看，用户不仅关注产品整体质量和价格，也较多讨论充电速度、电池续航、音质和使用体验等具体属性。这说明企业在营销中应突出不同产品类别最受关注的核心卖点，例如耳机类强调音质与续航，充电类产品强调充电速度和质量，智能手表则重点展示电池、屏幕和功能体验。同时，产品团队可以持续监测评论中的高频属性和主题，将质量、电池、充电性能等反复出现的问题作为产品优化和售后改进的重点。

4. 哪些商品存在“高评分但负面评论”的异常，需要优先排查产品体验？



商品	商品评分	VADER 情感得分
Esquire Laundry Basket	4.3	-0.9399
Fire-Boltt Ninja Calling	4.2	-0.9273
Boult Dive+ Smartwatch	4.3	-0.8622

商品	商品评分	VADER 情感得分
Dell MS116 Mouse	4.5	-0.8380
Portronics Konnect L Cable	4.1	-0.8288

情感分析发现，部分商品虽然整体评分较高，但评论文本中仍表现出明显的负面情绪。例如，Dell MS116 Mouse 的商品评分达到 4.5，但 VADER 情感得分为 -0.8380；Esquire Laundry Basket 的评分为 4.3，但情感得分低至 -0.9399。这说明商品星级评分与评论文本表达的用户体验并不总是完全一致，仅依赖评分可能会忽略部分潜在的不满意信息。

因此，可以将“高评分但负面情感明显”的商品作为重点异常监测对象，进一步检查评论中是否反复出现质量、功能、使用体验或售后服务等问题。企业可以结合商品评分与评论情感建立异常监测机制，当高评分商品同时出现明显负面文本信号时及时进行人工排查，从而更早发现潜在的产品体验问题。

5. 综合价格、折扣、评分和关注度，营销资源应该优先投向哪些类目，哪些类目更需要优化？

类目	综合表现	商业策略
Electronics	用户关注度最高、折扣力度最大，评分整体较好	作为重点营销类目，但应控制过度折扣并关注促销效率
Computers&Accessories	价格、评分和关注度表现较均衡	保持稳定营销投入，并尝试组合销售和交叉推荐
Home&Kitchen	商品最多、价格最高，但用户关注度相对较低	优先优化高价低关注商品的定价、展示和促销策略
OfficeProducts	平均评分最高、折扣最低，但商品数量较少	可尝试增加曝光和交叉销售，而非依赖大幅降价

综合价格、折扣、评分和评价热度来看，不同商品类目适合采取不同的资源配置策略。Electronics 具有最高的用户关注度，可继续作为重点营销类目；Computers&Accessories 各项指标较为均衡，适合作为稳定投入的核心类目。相比之下，Home&Kitchen 虽然商品数量多且价格较高，但评价热度相对较低，因此更需要优先检查其中高价低关注商品的定价和展示策略。

OfficeProducts 的平均评分最高，同时折扣力度明显低于其他主要类目，说明该类目可以优先测试增加曝光、交叉销售等方式，而不必直接依赖更大的价格折扣。总体

而言，营销资源不应简单平均分配，而应根据不同类目的关注度、满意度和价格特征采取差异化策略。

三、 核心发现

本项目从商品、用户、评论文本和推荐系统多个维度对 Amazon 电商数据进行了综合分析。首先，不同商品类目的价格、折扣和评价热度存在明显差异。Electronics 的平均折扣率最高，为 57.34%，同时评分人数中位数达到 9,090，在四个主要类目中评价热度最高；Home&Kitchen 商品数量最多、平均价格最高，但评价热度相对较低；OfficeProducts 虽然商品数量较少，但平均评分最高，为 4.31。需要注意的是，评分人数反映的是评价热度和用户关注度，不能直接等同于销量。

用户行为方面，高活跃用户与普通用户表现出明显差异。高活跃用户平均评价 6.93 件商品，平均评分为 4.13，好评率达到 77.51%，平均活跃时间达到 1,041 天，均高于普通用户的相应水平，说明持续活跃用户具有更强的互动行为和更积极的评分倾向。

评论文本分析进一步显示，用户关注点主要集中在商品质量、价格、充电、电池续航、音质和整体使用体验等方面。LDA 主题建模中，General Product Experience 占 54.53%，Charging & Cables 占 24.38%，说明大量评论集中讨论产品整体体验以及充电和线缆相关问题。同时，情感分析发现部分高评分商品仍存在明显负面文本信号，表明仅观察星级评分可能遗漏用户在具体使用体验中的不满意信息。

在推荐系统实验中，Item-Based Collaborative Filtering 在统一训练集、测试集和评价指标下取得了四种模型中的最高结果，Hit Rate@10 为 12.12%，Precision@10 为 1.21%，Recall@10 为 12.12%。相比 Popularity-Based、User-Based CF 和 Truncated SVD，本次实验表明商品之间的评分行为相似性更适合当前数据条件下的 Top-10 推荐任务。

四、 商业建议

基于类目分析结果，可以采用差异化的营销资源配置策略。Electronics 具有较高的评价热度，可作为重点营销类目，但由于其平均折扣率已经较高，应重点关注促销效率，而不是持续依赖扩大折扣；Computers&Accessories 的价格、评分和关注度相对均衡，可以保持稳定投入，并尝试组合销售和交叉推荐；Home&Kitchen 应优先检查高价但关注度较低的商品，优化定价、商品展示和促销方式；OfficeProducts 则可以优先增加曝光和交叉销售，而不是简单扩大折扣。

在用户运营方面，可以将高活跃用户作为重点互动人群，通过个性化商品推荐、新品体验邀请、评价活动和定向优惠提高持续参与度。对于普通用户，则可以结合推荐系统和评价激励提升互动频率，逐步增加用户与平台之间的持续交互。由于当前数据没有真实消费金额，这里的运营策略应基于“高活跃用户”而不是将其直接定义为“高价值用户”。

在产品和客户体验管理方面，可以将评论中的质量、电池、充电、音质和使用体验等高频关注点作为营销卖点设计和产品优化的重要输入。同时，可以建立“商品评分 + 评论情感”的异常监测机制，对高分但出现明显负面文本信号的商品进行人工复查，以更早发现潜在的质量、功能、使用体验或售后问题。推荐系统方面，则可以优先将 Item-Based CF 作为当前数据条件下的推荐原型，并在后续获得更多用户行为、商品内容和订单数据后进一步优化个性化推荐效果。

五、 Generative AI 使用说明

本项目在完成过程中使用了 Generative AI 工具作为辅助工具。ChatGPT 主要用于协助理解部分数据分析与推荐系统方法、代码调试、分析思路梳理、报告语言修改以及演示文稿结构优化；OpenAI Codex 主要用于项目文件整理和 GitHub 仓库配置。项目中的数据处理、代码运行、模型实验、结果验证和最终分析均由本人完成并检查。Generative AI 生成的内容未被直接作为数据来源或分析证据使用。

References

Kaggle. (n.d.). Amazon Sales Dataset. [Amazon Sales Dataset](#)

Kaggle. (n.d.). Amazon Product Reviews. [Amazon Product Reviews](#)

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet allocation. *Journal of Machine Learning Research*, 3, 993–1022.

Hutto, C., & Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216–225. <https://doi.org/10.1609/icwsm.v8i1.14550>

Sarwar, B., Karypis, G., Konstan, J. A., & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. *Proceedings of the 10th International Conference on World Wide Web*, 285–295. <https://doi.org/10.1145/371920.372071>